
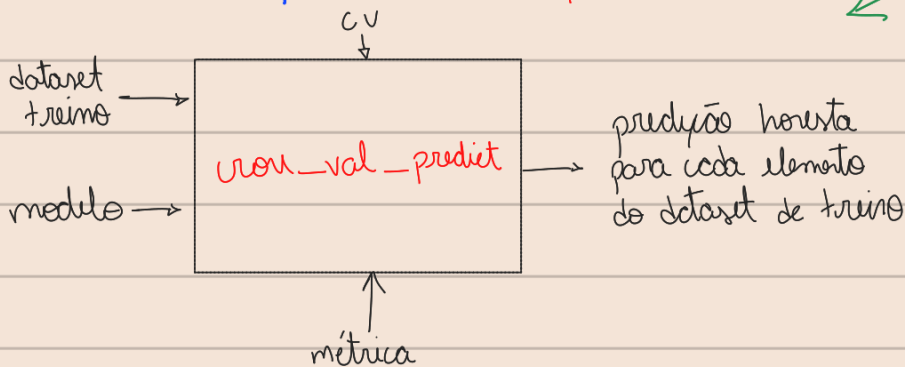


cross_val_score : avaliação de modelos honesta




Validação cruzada

cross_val_predict : previsões honestas



Matriz de confusão para classificação binária



métricas derivadas

$$\text{acurácia} = \frac{\# \text{ acertos}}{\# \text{ total}} = \text{"De todas as previsões quantos o modelo acertou"} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{precision} = \frac{\# \text{ de positivos corretamente classificados}}{\# \text{ todas classificações positivas}} = \text{"De todos que foram classificados como positivo quantos realmente são"} = \frac{TP}{TP + FP} \begin{matrix} \uparrow \text{ precision} \\ \downarrow \text{ FP} \end{matrix}$$

$$\text{recall} = \frac{\# \text{ de positivos corretamente classificados}}{\# \text{ todos classificados realmente positivos}} = \frac{\text{De todos que não realmente positivos quantos foram classificados como tal}}{\text{TP}} \uparrow \text{ recall} \quad \text{TP+FN} \downarrow \text{ FN}$$


* trade off precision recall \rightarrow \uparrow precision \downarrow recall

trade-off

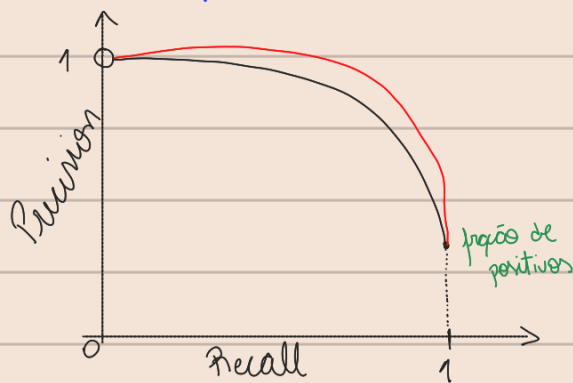
- **precision**: tem noção de **seletividade**
- **recall**: tem noção de **abrangência**

Decision function

dar uma nota score para um exemplo



Curva precision-recall



* sempre da para fazer recall = 100%, só precisa geral
 \hookrightarrow nesse caso precision = % positivos no dataset

metrca F1-score

• média harmônica de precision e recall

\hookrightarrow inverso da média dos inversos

$$\frac{1}{F1} = \text{média arit} \left(\frac{1}{\text{precision}}, \frac{1}{\text{recall}} \right)$$

$$\frac{1}{F1} = \frac{\left(\frac{1}{\text{precision}} + \frac{1}{\text{recall}} \right)}{2} \implies F1 = \frac{2}{\frac{1}{\text{precision}} + \frac{1}{\text{recall}}} = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

Sensitivity e Specificity

sensitivity: recall

specificity: True Negative Fraction "recall dos negativos" sem o de abrangência

alto recall → foca em dizer SIM
alto specificity → foca em dizer NÃO

exemplo Empréstimo

$$\text{specificity} = \frac{TN}{TN + FP}$$

		Predito	
		neg. emp	concede emp
Real	não pode pagar	TN	FP
	pode pagar	FN	TP

↑ recall: ↑% em conceder emp. só p/ quem pode pagar *alta chance do threshold ser baixo

↑ specificity: ↑% em recusar emp. p/ alguém que tem mínima chance de NÃO pagar

Nota:

$$\text{specificity} = \frac{TN}{TN + FP}$$


$$= \frac{TN + FP - FP}{TN + FP}$$

$$= \frac{TN + \cancel{FP}}{TN + \cancel{FP}} - \frac{FP}{TN + FP} \left\{ \begin{array}{l} FPF \\ \text{false positive fraction} \end{array} \right.$$

$$= 1 - FPF$$

$$FPF = 1 - \text{specificity}$$

Receiver Operating Characteristics curve ROC



A: alta **sensitivity** e baixa specificity

Ex: teste de covid


B: sensitivity e specificity balanceados

Ex: quando procura de **acurácia**

C: alta **sensitivity** e baixa **specificity**

Ex: julgamento criminal

Comparando modelos com a curva ROC



A: classificador perfeito

B: bom classificador

C: classificador fraco

D: aleatório

E: bom classificador, só que tem que inverter a predição ! erro de código

AUC: area under de curve $[0.5, 1]$